Anteproyecto TP Imágenes:
Segmentación y caracterización de tumores de mama en ecografía



Grupo 13
Integrantes:

- Lucía Burman (64229)
- Lucía Fernandez San Juan (64397)
- Agustina María Gallo (64205)

Fecha: 9 de octubre de 2026

1. Introducción

El cáncer de mama es el cáncer más frecuente en mujeres, tanto a nivel mundial como en Argentina. La detección temprana es el principal factor que mejora su pronóstico, por lo que contar con herramientas de diagnóstico accesibles y confiables es clave.

La ecografía mamaria cumple un rol central en ese proceso:

- es no invasiva y no usa radiación ionizante;
- es económica y está ampliamente disponible;
- es especialmente útil en mamas densas, donde la mamografía pierde sensibilidad.

Por eso se usa como complemento de la mamografía y como herramienta principal para caracterizar nódulos ya detectados. En este trabajo proponemos aplicar técnicas de procesamiento de imágenes biomédicas a ecografías mamarias para apoyar esa caracterización.

2. Problemática clínica

La interpretación de una ecografía mamaria es subjetiva y depende del operador, lo que genera variabilidad entre observadores al decidir si una lesión es benigna o maligna.

2.1 Limitaciones propias de la imagen ecográfica

- Ruido speckle de naturaleza multiplicativa, que degrada la textura y los bordes.
- Bajo contraste entre la lesión y el tejido circundante.
- Bordes difusos, que dificultan delimitar la lesión.
- Sombras acústicas que ocultan estructuras.
- Marcas y textos del ecógrafo superpuestos a la imagen.

2.2 El léxico BI-RADS

Para clasificar las lesiones, los radiólogos usan el léxico **BI-RADS**, que describe forma, orientación, margen, ecogenicidad y rasgos posteriores. Algunos rasgos que sugieren malignidad son:

- márgenes irregulares o espiculados;
- orientación "más alta que ancha";
- textura interna heterogénea;
- sombra acústica posterior.

2.3 Qué proponemos

Estos rasgos se evalúan a ojo, por lo que su lectura varía entre radiólogos. Este trabajo propone cuantificarlos objetivamente mediante procesamiento de imágenes, como herramienta de apoyo al diagnóstico (no como reemplazo del criterio médico).

3. Objetivo

Se busca desarrollar un algoritmo que realice el procesamiento de la imagen de ecografía mamaria, realice el pre-procesamiento de la imagen, realice segmentación de la lesión y extraiga descriptores de forma, intensidad y textura con el objetivo de identificar si la lesión es maligna o benigna.

Específicamente se busca:

- Caracterizar el dataset: resolución espacial, profundidad de bits, distribución de clases, histogramas por clase y presencia de artefactos (calipers, textos y escalas del ecógrafo), y modelar estadísticamente el ruido speckle como ruido multiplicativo con distribución Gamma.
- Implementar y comparar técnicas de mejoramiento en el dominio espacial (promediador, gaussiano, mediana), frecuencial (pasabajos Butterworth y gaussiano) y óptimo (filtro de Wiener) para reducir el speckle, y técnicas de realce de contraste como la ecualización de histograma, evaluándolas en términos de brillo, contraste, SNR y nitidez.
- Detectar y reconstruir las regiones ocupadas por marcas y textos superpuestos del ecógrafo mediante operaciones morfológicas (top-hat, transformada hit-or-miss, etiquetado) y técnicas de relleno o *inpainting*, validando la reconstrucción sobre marcas sintéticas.
- Evaluar el efecto de la compresión con pérdida (reducción de profundidad de bits y JPEG) sobre la calidad de imagen, mediante MSE y PSNR, y sobre la estabilidad de los descriptores extraídos.
- Segmentar la lesión con técnicas vistas en clase (umbralizado de Otsu, crecimiento de regiones, watershed y contornos activos de Chan-Vese) y validar el resultado contra las máscaras manuales del dataset mediante el índice de superposición IoU.
- Extraer descriptores de forma, margen, intensidad y textura inspirados en BI-RADS, como circularidad, orientación, irregularidad del contorno, ecogenicidad relativa al tejido circundante y sombra acústica posterior.
- Determinar mediante pruebas estadísticas qué descriptores diferencian lesiones benignas de malignas, y entrenar un clasificador simple evaluado por validación cruzada en términos de sensibilidad y especificidad.
- Como objetivo de máxima, desarrollar una interfaz gráfica que permita cargar una ecografía, marcar la lesión con un clic (usado como semilla de la segmentación) y visualizar la segmentación, los descriptores y la clasificación sugerida.

4. Materiales: base de datos

Usaremos el Breast Ultrasound Images Dataset (BUSI), disponible en Kaggle (Medical Images in Kaggle, fuente sugerida por la cátedra).

El dataset reúne 780 ecografías de mama de 600 pacientes mujeres de entre 25 y 75 años, adquiridas en 2018 en el Baheya Hospital (El Cairo, Egipto) con equipos LOGIQ E9. Las imágenes están en formato PNG, en escala de grises, con un tamaño aproximado de 500 × 500 píxeles, y se dividen en tres clases: normal (133), benigno (437) y maligno (210).

Además, cada imagen con lesión viene acompañada de una máscara binaria de segmentación dibujada manualmente por radiólogos: una imagen del mismo tamaño donde los píxeles de la lesión valen 1 (blanco) y el resto vale 0 (negro). Esta máscara funciona como ground truth ("verdad de referencia"), es decir, la respuesta correcta contra la cual comparamos lo que produce nuestro algoritmo. Las máscaras también nos permiten calcular los descriptores sobre una segmentación confiable, para separar los errores de segmentación de la capacidad real de los descriptores para distinguir lesiones benignas de malignas.

Artículo de referencia: Al-Dhabyani W., Gomaa M., Khaled H., Fahmy A. *Dataset of breast ultrasound images.* Data in Brief 28 (2020) 104863.

5. Metodología propuesta

Se parte de la hipótesis de trabajo de que las lesiones malignas presentan, frente a las benignas forma más irregular (menor circularidad y solidez) y orientación "más alta que ancha", entre otras características que ya fueron mencinoadas.

La metodología se organiza en siete etapas secuenciales, que van desde la caracterización de los datos hasta el desarrollo de una interfaz de usuario para la validación del sistema.

5.1. Etapa de contextualización

Se realizará una descripción del proceso de formación de la imagen ecográfica y del fenómeno de *speckle*. Con este fin, se llevará a cabo un análisis exploratorio del conjunto de datos (*dataset*) que contemplará los siguientes aspectos: dimensiones de las imágenes, rango dinámico, histogramas por clase, desbalance entre clases y presencia de artefactos superpuestos.

5.2. Etapa de preprocesamiento

5.2.1. Mejoramiento

Se procurará reducir el ruido tipo *speckle* mediante filtros de media, mediana y gaussiano, así como filtrado en el dominio frecuencial a través de la Transformada Rápida de Fourier (FFT). Adicionalmente, se aplicará realce de contraste mediante ecualización de histograma. Las técnicas empleadas se compararán cuantitativamente a partir de la relación señal-ruido (SNR) y de la preservación de bordes.

5.2.2. Reconstrucción

Se detectarán las marcas de medición y los textos superpuestos por el ecógrafo mediante umbralización y operaciones morfológicas. Posteriormente, los píxeles afectados serán reconstruidos mediante técnicas de *inpainting*, con el fin de evitar que dichos elementos contaminen la segmentación y el análisis de textura.

5.3. Etapa de segmentación

Se implementará un enfoque semiautomático en el que, a partir de una semilla ubicada en el interior de la lesión, se aplicarán *region growing* y contornos activos. Estos resultados se compararán con métodos automáticos de referencia: umbralización de Otsu, umbral adaptativo y *k-means*.

La segmentación obtenida se refinará mediante operaciones morfológicas (apertura, cierre y relleno de huecos) y etiquetado de componentes conexas, conservando únicamente la región que contiene la semilla. La validación se realizará frente a las máscaras manuales, empleando el coeficiente de Dice y el índice de Jaccard (IoU) como métricas.

5.4. Etapa de extracción de características

Se extraerán tres familias de descriptores:

- Textura: matriz de co-ocurrencia de niveles de gris (GLCM) calculada en el interior de la lesión, en cuatro direcciones (0°, 45°, 90° y 135°) y para varias distancias.
- Intensidad: media, desvío estándar, ecogenicidad relativa al tejido circundante y sombra acústica posterior (intensidad en la región ubicada por debajo de la lesión).
- Forma (criterios BI-RADS): área, relación alto/ancho, circularidad, solidez (a partir de la envolvente convexa o *convex hull*) e irregularidad del contorno.

5.5. Etapa de resultados y diagnóstico

Se presentará la distribución de los descriptores mediante diagramas de caja (*boxplots*) por clase y se evaluará la significancia estadística de cada uno mediante la prueba U de Mann-Whitney. Asimismo, se implementará un clasificador simple (regresión logística por ejemplo) con validación cruzada estratificada y estrategias de manejo del desbalance de clases.

El desempeño se evaluará con distintas métricas. Finalmente, se compararán los resultados obtenidos con la segmentación propuesta frente a los alcanzados con las máscaras manuales.

5.6. Interfaz de usuario

Se desarrollará una aplicación en Streamlit o Tkinter que permita cargar una ecografía, seleccionar la lesión mediante un clic y visualizar la máscara superpuesta, los descriptores calculados y la clasificación sugerida. Esta herramienta permitirá, además, evaluar los «casos incógnita» provistos por la cátedra.

5.7. Herramientas a utilizar

Se utilizarán Python 3, NumPy, scikit-image, OpenCV, SciPy, scikit-learn, Matplotlib, pandas y Streamlit (interfaz).
El código se organiza en un repositorio de GitHub, con commits incrementales y distribuidos entre todas las integrantes.