Anteproyecto TP Imágenes:
Caracterización del speckle y segmentación de tumores de mama en ecografía

Versión revisada según devolución de la cátedra



PSIB 2026Q2 – TPI – Grupo 13

Integrantes:

- Lucía Burman (64229)
- Lucía Fernandez San Juan (64397)
- Agustina María Gallo (64205)

Fecha: 15 de octubre de 2026

1. Introducción

El cáncer de mama es el cáncer más frecuente en mujeres, tanto a nivel mundial como en Argentina. La detección temprana es el principal factor que mejora su pronóstico, por lo que contar con herramientas de diagnóstico accesibles y confiables es clave.

La ecografía mamaria cumple un rol central en ese proceso:

- es no invasiva y no usa radiación ionizante;
- es económica y está ampliamente disponible;
- es especialmente útil en mamas densas, donde la mamografía pierde sensibilidad.

Por eso se usa como complemento de la mamografía y como herramienta principal para caracterizar nódulos ya detectados. En este trabajo proponemos aplicar técnicas de procesamiento de imágenes biomédicas a ecografías mamarias para apoyar esa caracterización.

2. Problemática clínica

La interpretación de una ecografía mamaria es subjetiva y depende del operador, lo que genera variabilidad entre observadores al decidir si una lesión es benigna o maligna.

2.1 Limitaciones propias de la imagen ecográfica

- Ruido *speckle* de naturaleza multiplicativa, que degrada la textura y los bordes. El *speckle* no es solo ruido: también es textura, y puede confundirse con la textura propia del tejido.
- Bajo contraste entre la lesión y el tejido circundante.
- Bordes difusos, que dificultan delimitar la lesión.
- Sombras acústicas que ocultan estructuras.
- Marcas y textos del ecógrafo superpuestos a la imagen (*calipers*, escalas), que no son tejido pero alteran la intensidad y la textura.

2.2 El léxico BI-RADS

Para clasificar las lesiones, los radiólogos usan el léxico **BI-RADS**, que describe forma, orientación, margen, ecogenicidad y rasgos posteriores. Algunos rasgos que sugieren malignidad son:

- márgenes irregulares o espiculados;
- orientación "más alta que ancha";
- textura interna heterogénea;
- sombra acústica posterior.

2.3 Qué proponemos

Estos rasgos se evalúan a ojo, por lo que su lectura varía entre radiólogos. Este trabajo propone cuantificarlos objetivamente mediante procesamiento de imágenes, como herramienta de apoyo al diagnóstico (no como reemplazo del criterio médico). El eje del trabajo es entender el *speckle* y la textura de la imagen ecográfica, y usar ese conocimiento para fundamentar cómo se segmenta la lesión.

3. Objetivos

Objetivo general: caracterizar el ruido y la textura de las ecografías mamarias y, a partir de ese análisis, definir y validar un método de segmentación de la lesión que permita extraer descriptores para diferenciar lesiones benignas de malignas.

Objetivos específicos:

1. **Caracterizar el ruido *speckle*.** Analizar el dataset (resolución, rango dinámico, histogramas por clase, desbalance) y modelar estadísticamente el *speckle* en regiones homogéneas de tejido. Para eso se ajustarán distribuciones candidatas (Rayleigh, Gamma), se estudiará la relación media/desvío y se verificará su carácter multiplicativo (varianza local en función de la media, antes y después de una transformación logarítmica).
2. **Reconstruir las regiones con marcas del ecógrafo.** Detectar los *calipers*, textos y escalas superpuestos mediante umbralización y operaciones morfológicas (*top-hat*, etiquetado) y reconstruir esos píxeles por *inpainting*, validando la reconstrucción sobre marcas sintéticas agregadas a regiones limpias. Así se evita que las marcas contaminen la caracterización del ruido, los mapas de textura y la segmentación.
3. **Comparar el filtrado en el dominio espacial y en el frecuencial.** Del lado espacial se usarán filtros promediador, gaussiano y de mediana; del frecuencial, pasabajos ideal, Butterworth y gaussiano. La comparación no se limitará a la reducción de ruido: se identificarán las particularidades texturales que cada dominio conserva o pierde (granularidad, bordes, patrón interno de la lesión), mediante GLCM, espectro de potencia y métricas de suavizado y de preservación de bordes.
4. **Construir mapas de características.** Antes de definir la segmentación, se calcularán mapas locales con ventana deslizante: media y varianza local, coeficiente de variación, propiedades de la GLCM (contraste, homogeneidad, energía, correlación, entropía) y gradiente. Luego se evaluará, con las máscaras manuales, cuáles separan mejor la lesión del tejido circundante.
5. **Segmentar la lesión.** Se aplicarán técnicas vistas en clase (crecimiento de regiones a partir de una semilla, *k-means* sobre los mapas seleccionados y contornos activos de Chan-Vese), con refinamiento morfológico, y se validará el resultado contra las máscaras manuales mediante Dice e IoU.
6. **Diferenciar lesiones benignas y malignas.** Se extraerán descriptores de forma, intensidad y textura inspirados en BI-RADS. Con la prueba U de Mann-Whitney se determinará cuáles diferencian ambas clases, y se evaluará un clasificador simple.

Objetivo opcional: interfaz gráfica que permita cargar una ecografía, marcar la lesión con un clic (semilla de la segmentación) y visualizar los mapas, la segmentación y los descriptores.

4. Materiales: base de datos

Usaremos el *Breast Ultrasound Images Dataset* (BUSI), disponible en Kaggle (Medical Images in Kaggle, fuente sugerida por la cátedra).

El dataset reúne 780 ecografías de mama de 600 pacientes mujeres de entre 25 y 75 años, adquiridas en 2018 en el Baheya Hospital (El Cairo, Egipto) con equipos LOGIQ E9. Las imágenes están en formato PNG, en escala de grises, con un tamaño aproximado de 500 × 500 píxeles, y se dividen en tres clases: normal (133), benigno (437) y maligno (210).

Cada imagen con lesión viene acompañada de una **máscara binaria de segmentación** dibujada manualmente por radiólogos. Esta máscara funciona como *ground truth*, con tres usos en el

trabajo:

- validar nuestra segmentación;
- evaluar qué mapas de características separan mejor la lesión del tejido;
- calcular los descriptores sobre una segmentación confiable, para separar los errores de segmentación de la capacidad real de los descriptores.

Artículo de referencia: Al-Dhabyani W., Gomaa M., Khaled H., Fahmy A. *Dataset of breast ultrasound images.* Data in Brief 28 (2020) 104863.

Estado del arte: sobre este dataset predominan los enfoques de *deep learning* (U-Net, Attention U-Net) para segmentación y las redes convolucionales para clasificación. Nuestro trabajo propone un enfoque clásico e interpretable, en el que cada decisión del método (filtro, mapa, técnica de segmentación) queda justificada por un análisis previo. Los resultados se compararán con los reportados por esos métodos.

5. Metodología propuesta

Hipótesis de trabajo: el *speckle* sigue un modelo multiplicativo cuya distribución puede caracterizarse en tejido homogéneo. La lesión se distingue del tejido circundante no solo por su intensidad sino también por su textura local, y existen mapas de características que hacen esa diferencia más evidente que la imagen original. Las lesiones malignas presentan, frente a las benignas, forma más irregular (menor circularidad y solidez), orientación "más alta que ancha" y textura interna más heterogénea.

La metodología se organiza en seis partes. Cada una usa los resultados de la anterior:

5.1. Contextualización y reconstrucción de artefactos

Análisis exploratorio del dataset: dimensiones, rango dinámico, histogramas por clase, desbalance entre clases y presencia de marcas superpuestas. Descripción de la formación de la imagen ecográfica y del fenómeno de *speckle*.

Las marcas del ecógrafo (*calipers*, textos, escalas) son estructuras pequeñas y mucho más brillantes que el tejido. Se detectarán con transformada *top-hat*, umbralización y etiquetado de componentes conexas (filtrando por tamaño y forma), y los píxeles detectados se reconstruirán por *inpainting* a partir de su vecindad. Para validar la reconstrucción, se agregarán marcas sintéticas a regiones sin artefactos y se comparará la región reconstruida con la original (MSE, PSNR). Esta limpieza no reduce el *speckle*, pero evita que las marcas contaminen las etapas siguientes.

5.2. Caracterización del ruido

Sobre las imágenes limpias, selección de parches homogéneos de tejido y estudio de su histograma. Ajuste de distribuciones (Rayleigh, Gamma) y comparación de la bondad del ajuste. Cálculo de la relación media/desvío. Análisis de la varianza local en función de la media para verificar el modelo multiplicativo, antes y después de aplicar logaritmo. Se discutirá cuánto se apartan las imágenes del modelo teórico, dado que el ecógrafo aplica compresión logarítmica y post-procesamiento.

5.3. Comparación de dominios (mejoramiento)

Reducción del *speckle* con filtros espaciales (promediador, gaussiano, mediana) y frecuenciales sobre la FFT (pasabajos ideal, Butterworth, gaussiano), con distintos tamaños de ventana y

frecuencias de corte. Para cada resultado se medirá:

- el suavizado en zonas homogéneas (SNR / número equivalente de *looks*);
- la preservación del borde de la lesión (gradiente sobre el contorno de la máscara);
- el espectro de potencia;
- los descriptores GLCM dentro y fuera de la lesión.

Así se identificará qué particularidades texturales conserva o pierde cada dominio, y qué filtrado conviene como entrada de las etapas siguientes.

5.4. Mapas de características

Sobre la imagen filtrada se calcularán mapas locales con ventana deslizante: media, varianza y coeficiente de variación local, propiedades de la GLCM (contraste, homogeneidad, energía, correlación, entropía) y magnitud del gradiente. Para cada mapa se medirá la separabilidad entre la lesión y un anillo de tejido circundante, usando las máscaras manuales (área bajo la curva ROC, razón de Fisher). Los mapas con mayor separabilidad serán la base de la segmentación.

5.5. Segmentación

Enfoque semiautomático: a partir de una semilla en el interior de la lesión se aplicarán crecimiento de regiones, *k-means* sobre el vector de mapas seleccionados y contornos activos de Chan-Vese. El resultado se refinará con operaciones morfológicas (apertura, cierre, relleno de huecos) y etiquetado de componentes conexas, conservando la región que contiene la semilla. La validación se hará contra las máscaras manuales con el coeficiente de Dice y el índice de Jaccard (IoU), comparando la segmentación sobre la imagen original y sobre los mapas.

5.6. Descriptores y diagnóstico

Se extraerán tres familias de descriptores:

- **Forma (BI-RADS):** área, relación alto/ancho, circularidad, solidez e irregularidad del contorno.
- **Intensidad:** media, desvío, ecogenicidad relativa al tejido circundante y sombra acústica posterior.
- **Textura:** GLCM en el interior de la lesión, en cuatro direcciones y varias distancias.

Se presentará la distribución de cada descriptor por clase (*boxplots*) y se evaluará su significancia con la prueba U de Mann-Whitney. Se entrenará un clasificador simple (regresión logística) con validación cruzada estratificada y manejo del desbalance de clases, y se evaluará con sensibilidad, especificidad y AUC. Los resultados obtenidos con la segmentación propia se compararán con los obtenidos con las máscaras manuales.

5.7. Herramientas

Python 3, NumPy, SciPy, scikit-image, OpenCV, scikit-learn, pandas y Matplotlib (Streamlit para la interfaz opcional). El código se organiza en un repositorio de GitHub, con un módulo por cada parte de la metodología y commits incrementales distribuidos entre todas las integrantes.

6. Cambios respecto de la versión anterior

Según la devolución de la cátedra, se redujo la cantidad de objetivos para profundizar en el eje principal:

- **Se quitó** la evaluación de la compresión de imágenes.

- **Se quitó** el filtro de Wiener para el *denoising*.
- **Se mantuvo** la reconstrucción de las marcas del ecógrafo por *inpainting*, como paso previo que evita que las marcas contaminen el análisis de ruido, textura y segmentación.
- **Se profundizó** la caracterización del ruido y la comparación de dominios, con foco en las particularidades texturales de cada uno.
- **Se incorporó** la construcción de mapas de características como paso previo que fundamenta la elección del método de segmentación.